ML ENGINEER PORTFOLIO · 2026.11

이성원

Sungwon (Alex) Lee

예측 모델을 운영 서버까지 가져가는 ML 엔지니어

통계와 머신러닝을 공부했고, 지금은 에너지 회사에서 전력 사용량 예측 모델을 만들어 서비스 서버에 올리는 일을 합니다. 모델을 고르는 일만큼, 실험에서 나온 숫자가 운영 경로에서도 그대로 나오는지 확인하는 데 시간을 씁니다.

이메일 sungwonlee.alex@gmail.com

LinkedIn linkedin.com/in/sungwonalexlee

CONTENTS

01 소개 02

02 경력 · 학력 03

03 기술 04

04 LH 홈닉 단지 전력 사용량 예측 05
헤리트 · 대표 프로젝트

05 Lost in Quantization 10
AAAI-27 워크숍 논문

06 한국 주식 수익률 예측 검증 12
개인 프로젝트

07 그 밖의 프로젝트 13

01 소개

UCLA에서 통계·데이터과학을, CMU에서 Data Analytics for Science 석사를 마쳤습니다. 2025년 7월부터 헤리트에서 전문연구요원으로 근무하며 아파트 단지 전력 예측, 수요반응 서비스용 AI 에이전트, 전력 거래 자동화를 맡고 있습니다.

가장 오래 붙잡은 일은 LH 홈닉 77개 단지의 다음 날 전력 사용량 예측입니다. Python 3.7 · CPU 8코어 서버 안에서 학습과 추론이 끝나야 하는 조건이었고, 그 서버에 설치할 수 없는 시계열 파운데이션 모델 Chronos-2와 같은 수준(R^2 0.879 vs 0.881)의 정확도를 냈습니다.

학력	Carnegie Mellon University, MS Data Analytics for Science (2024.05, GPA 4.06/4.33) UCLA, BS Statistics and Data Science (2023.06)
병역	전문연구요원(현역) 복무 중 · 2025.07 ~
언어	한국어 모국어 · 영어 업무 가능 (미국 학부·석사, 미국 기업 인턴십 2회)

같은 행끼리 비교합니다

모델 비교는 같은 단지 · 같은 시각끼리 짝지어 MAE와 R^2를 함께 봅니다. LH 프로젝트에서 한 주 결과만 보고 신경망과 기준 모델이 동률(MAE −1.0%)이라 판단할 뻔했는데, 원인은 두 경로의 기준선 계산 차이였습니다. 같은 경로로 30일을 다시 재니 MAE가 22% 낮았습니다.

좋은 숫자부터 의심합니다

실험 성능이 운영 재현보다 17% 좋게 나온 원인이 전처리 단계의 미래 정보 누설이라는 걸 찾아냈습니다. 개인 주가 예측 프로젝트에서는 중첩 표본으로 t값이 3~4배 부풀고 생존편향이 섞여 있던 결과를 직접 다시 검증해 걷어냈습니다.

모델보다 데이터를 먼저 봅니다

LH 신경망의 폭 · 층 수 · 입력 길이를 바꾼 실험은 대부분 차이가 없거나 나빠졌습니다. 성능을 올린 것은 시점 기준으로 다시 만든 학습 데이터와, 사내 API에 남아 있던 기상 관측 · 예보 과거 데이터 백필이었습니다.

02 경력 · 학력

2025.07 - 현재

헤리트 (Herit Corp.) Data Scientist (Manager) · 전문연구요원

- LH 홈닉 77개 단지 전력 사용량 예측 모델 개발, 서비스 담당자에게 운영 이관 → 04
- 래미안 원펄라 1,000세대 이상 에너지 사용량 예측 모델 배포, 누진 구간 사전 알림
- 수요반응(DR) 서비스 VoC 응답 자동화 AI 에이전트 HERIA 개발, 응답 속도 60% 개선
- 예측과 강화학습으로 KPX 입찰 전략을 최적화하는 전력 거래 자동화 플랫폼 구축

2024.09 - 2024.12

Ferveret Inc. Data Science Intern · 원격(San Jose, CA)

- 데이터센터 냉각 시스템 전력 소비 예측 모델 개발, 에너지 효율 15% 개선
- 데이터센터 운영 데이터 분석으로 운영비 10% 절감 패턴 도출, 시니어 엔지니어 대상 발표

2024.06 - 2024.08

PricewaterhouseCoopers Deals Consulting Intern · San Francisco, CA

- M&A 계약 분리 분석, 인력 시나리오 계획 도구 설계 지원(간접비 12% 절감)

2024.01 - 2024.05

Ansys × CMU 캡스톤 Data Scientist · Pittsburgh, PA

- 클라우드 시뮬레이션 메모리 사용량 예측 RNN 개발, 시뮬레이션 정확도 20% 개선
- 클라우드 시뮬레이션 데이터 파이프라인 최적화로 계산 시간 30% 단축

학력

Carnegie Mellon University
MS Data Analytics for Science · GPA 4.06/4.33
2024.05 졸업

University of California, Los Angeles
BS Statistics and Data Science · 전공 GPA 3.60/4.00
2023.06 졸업

연구

Lost in Quantization
AAAI-27 Workshop on Deployable AI 제출 → 05
2026.11

활동

CMU 컴퓨터과학대학 대학원 조교 (Communications for Software Leaders II) 2024.01-06

Google Developer Student Club CMU, CFO 2023.08-2024.06

아이스하키 U-18 국가대표 부주장, 2018 IIHF U18 세계선수권 Div II A · UCLA 아이스하키팀 (ACHA D2)

03 기술

분야	도구	쓴 곳
모델링	PyTorch · TensorFlow 2 / Keras · scikit-learn · LightGBM · Hugging Face Transformers	LH 예측 신경망(TF 2.5, 커스텀 레이어 5종, .h5 배포)과 HGB · CoGenCast 부분 미세조정
시계열	분위수 회귀 · Chronos-2 · TimesFM 2.5 · 구간 보정 · CRPS	파운데이션 모델을 비교 기준으로 사용 · 80% 구간 적중률 보정(72.9% → 78.8%)
LLM	vLLM · NVFP4 / ModelOpt 양자화 · Ollama · JSON 스키마 강제 출력	양자화 안전성 논문(2,014쌍 × 3개 모델) · 로컬 음성 비서
데이터	pandas · NumPy · SQL · Spark · Parquet	15분 계측 원본 → 시점 기준 패널 · 사내 기상 API 2년치 백필
운영	Linux · cron 배치 · conda / uv · 폴백 · manifest · 재학습 게이트	LH 서빙: CPU 8코어에서 하루 예측 16초, 실패 시 단계별 대체 발행
평가	대응 비교(MAE · R^2 · 승패) · 부트스트랩 CI · Newey-West t · 사람 라벨 검증	모든 프로젝트의 모델 선택 · 논문의 판정기 검증(블라인드 라벨)
GPU (학습 중)	CUDA · Triton · PyTorch C++ 확장(TORCH_LIBRARY)	커널 작성 연습 · 사내 배포용 확장 템플릿과 벤치마크
그 외	R · MPI · MLflow · Azure · Tableau	대학원 수업과 인턴십

04 LH 홈닉 단지 전력 사용량 예측

기간 2026.08 – 2026.11 **소속** 헤리트 **역할** 데이터 정제 · 모델링 · 평가 · 서빙 코드 · 인계 (1인) **기술** TensorFlow 2.5 · scikit-learn HGB · pandas · Chronos-2(비교 기준)

문제

LH 홈닉 서비스 대상 77개 아파트 단지의 다음 날 24시간 전력 사용량을 시간 단위로 예측합니다. 하루 전 06시에 한 번 내고, 당일 02시에 전날 밤까지의 데이터로 다시 냅니다.

지켜야 했던 조건

1. 학습 · 추론 · 관리가 모두 **서비스 서버 안에서** 끝나야 함 (Python 3.7 · TensorFlow 2.5 · CPU 8코어, GPU 없음)
2. 계측이 자주 끊기는 **부분수집 단지 47곳도 빠짐없이** 예측 (정상 30 + 부분수집 47)
3. 배포 기준: 전 단지 **R^2 평균 0.82 이상**, 현행 모델보다 좋을 것

결과

하루 전 06시 예측

0.879 R^2

MAE 2.61 kW

당일 02시 재예측

0.898 R^2

MAE 2.37 kW (하루 전 대비 −9%)

74단지 · 같은 시간 대응	R^2 평균	0.82↑ 단지	MAE
당일 02시 재예측	**0.898**	**64**	**2.37 kW**
하루 전 06시 예측	**0.879**	**63**	**2.61 kW**
Chronos-2 하루 전 (서버 설치 불가)	0.881	63	2.67 kW

현행 원모델(HGB) 대비 R^2 **0.842 → 0.884**, MAE **3.03 → 2.56 kW** (68단지). 하루 예측은 8코어에서 **16초**, 메모리 1.4 GB입니다.

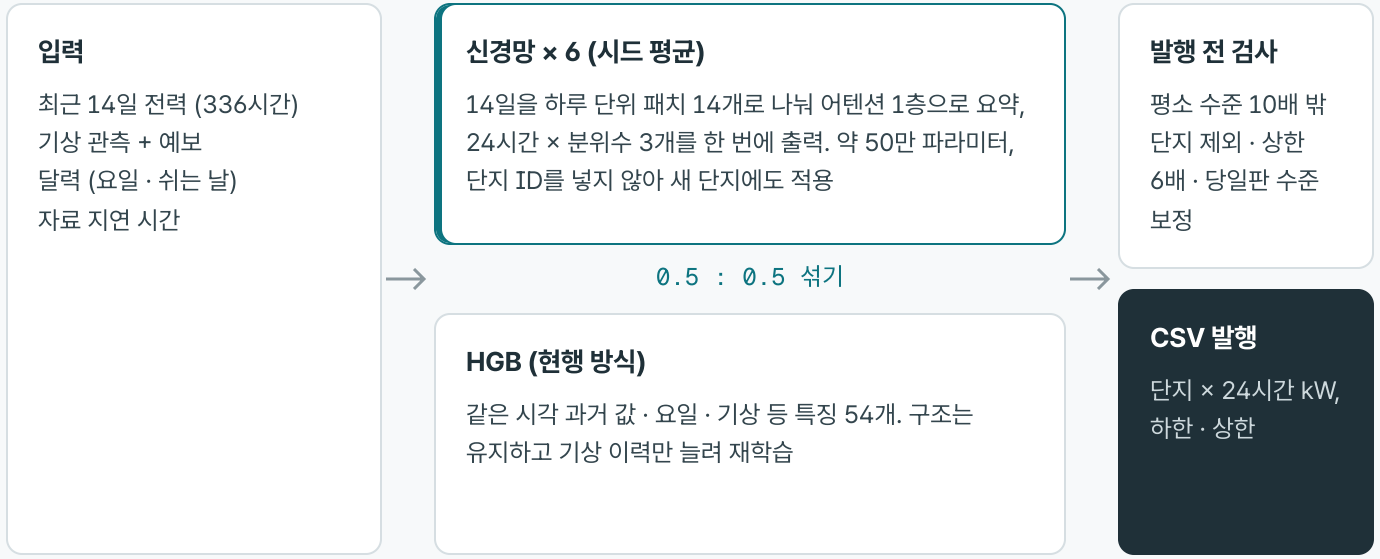
1월 · 2월 · 봄(3~6월) · 8월, 총 210일을 운영 스크립트 그대로 재현해 채점했습니다.

서버에 못 올리는 모델은 기준으로 두고, 올릴 수 있는 모델을 만들었습니다

1 Chronos-2 제로샷이 가장 정확했습니다. 8월 기준 현행 모델보다 MAE가 약 30% 낮았지만, Python 3.9 이상 전용이라 서버(3.7)에 설치할 수 없었습니다.

2 ONNX 변환은 Python 3.7 onnxruntime에서 로드까지 확인했지만, 서버에 새 런타임을 들이는 운영 부담 때문에 접었습니다. 지식 증류는 교사 모델을 서버에서 돌릴 수 없어 성립하지 않았습니다.

3 Chronos-2는 **남은 격차를 재는 기준**으로 남기고, 서버의 TF 2.5에서 그대로 학습 · 저장 · 로드되는 작은 신경망을 설계했습니다. 현행 방식인 HGB와 반씩 섞어 발행합니다.



왜 섞었나

원본 시계열을 보는 신경망과 요약 특징을 보는 HGB는 틀리는 방향이 다릅니다. 비율 0.3~0.8을 시험했고 0.5가 가장 좋았습니다.

스파이크에 강한 정규화

표본별 정규화를 평균 · 표준편차 대신 중앙값 · IQR로 바꾸고 ±8에서 잘랐습니다. 계량기 이상값 하나가 예측을 폭주시킨 사고 이후의 수정입니다.

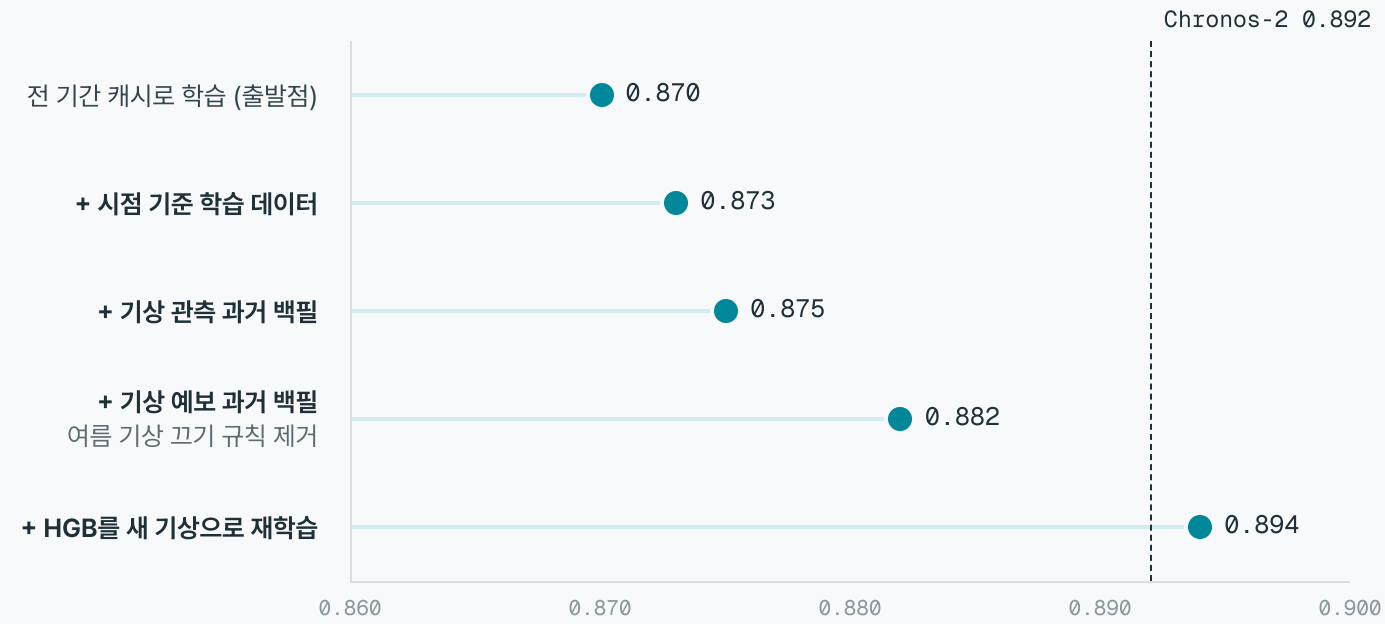
구버전 환경 대응

TF 2.5 + NumPy 1.21 조합에서 Keras LayerNormalization이 깨져 직접 구현했고, .h5 저장이 되도록 상수를 쓰는 레이어는 모두 커스텀 레이어로 바꿨습니다.

성능을 올린 건 모델 설정이 아니라 데이터 작업이었습니다

데이터 작업을 하나씩 더할 때의 R^2 (하루 전 예측, 섞은 결과)

Chronos-2 비교군 42단지 · 같은 시간 대응 · 네 기간 운영 재현



가로축은 0.860에서 시작합니다. 설계와 채점을 같은 네 기간에서 했기 때문에, 최종 보고는 부분수집 단지를 포함한 전 단지 기준(0.879 vs Chronos-2 0.881)으로 "대등"이라고 했습니다.

효과가 없던 모델 쪽 시도

- 신경망 폭 32 · 48 · 96 · 128, 블록 수 변경
- 입력 길이 28일 · 56일 (14일이 가장 좋음)
- dropout, 배치 크기, 조기 종료 기준 변경
- 시드 3개 → 6개 앙상블만 소폭 이득

조기 종료 검증 손실이 좋은 설정일수록 시험 R^2가 나빴습니다. 검증 신호를 바꿔도 결과가 같아, 이 데이터에서 모델 쪽 손잡이는 거의 다 썼다고 판단했습니다.

여름에 기상을 넣으면 나빠졌던 이유

기상 이력이 겨울 몇 달뿐이라, 모델이 난방기 관계(기온 1°C당 부하 −0.4%)를 배워 냉방기(+2.8%)에 거꾸로 적용했습니다. 처음엔 계절별로 기상을 끄는 규칙을 결과를 보기 전에 정해 두고 안 본 기간으로 검증했고, 이후 사내 API에서 2024년 9월부터의 예보를 받아 채워 규칙 자체를 없앴습니다.

트러블슈팅

LEAKAGE

실험 성능이 운영 재현보다 17% 좋게 나옴

원인 학습 데이터를 전 기간 캐시에서 잘라 썼는데, 결측 채우기가 앞뒤 값을 보기 때문에 정보 컷 이후의 값이 입력에 섞였습니다. 입력 마지막 24시간에서 운영과 다른 칸이 평균 6.4% 였습니다.

해결 날짜마다 그 시각까지의 원본만으로 패널을 다시 만들어 학습 표본을 생성했습니다(31,377개, 4프로세스 40분).

결과 봄 기간에 HGB보다 뒤지던 결과가 앞서는 쪽으로 바뀌었습니다. 같은 점검을 HGB에도 했지만 R^2 차이가 0.000이라 HGB는 그대로 두었습니다.

ROBUSTNESS

계량기 스파이크 하나로 한 단지 R^2가 −881

원인 평소의 약 1,290배인 15분 값이 이상치 처리를 통과해 14일간 입력에 남았고, 표본 표준편차가 9에서 809로 커져 정규화가 폭주했습니다.

해결 중앙값 · IQR 정규화, ±8 윈저화, 발행 전 상한(입력 중앙값의 6배). 이후 입력 전체가 오염된 단지(최대 10.8 kW에 13,454 kW 예측)도 나와, 단지별 평소 수준표 기준 10배 밖이면 발행하지 않게 했습니다.

결과 1월 신경망 평균 R^2 −19.26 → 0.781. 배포 기준을 중앙값이 아닌 평균으로 둔 덕분에 배포 전에 발견했습니다.

COVERAGE

검침 도착 시각이 단지마다 다름

원인 모든 단지에 같은 정보 컷을 적용하면 늦게 들어오는 단지가 빠집니다. 2026-08-26 재현에서 77곳 중 29곳만 예측됐습니다.

해결 지연 시간을 모델 입력으로 넣고 학습 때 무작위로 흔들었습니다. 이력이 14일이 안 되는 단지는 가진 날을 반복해 채우고, 한 달 넘게 끊긴 단지만 제외합니다.

결과 예측 비율 74.1% → 77.4%. 남은 제외는 대부분 실측값도 없는 단지입니다.

TRAINING

운영 모델 6개 중 3개가 발산한 채 저장됨

원인 평소의 536~2,882배인 오염 표본이 학습에 섞여 기울기가 폭발했습니다. 같은 시드도 스레드 순서에 따라 5번 중 3번 발산했습니다.

해결 서빙과 같은 입력 검사로 학습 표본을 거르고(13개 제외), 30에폭 전에 멈추면 경고, 재학습 후 모델별 학습 에폭과 검증 손실을 자동 점검하게 했습니다.

결과 재학습 6개 모두 정상 수렴(42~67에폭). 모델 교체 전에 학습 기록을 확인하는 절차가 생겼습니다.

운영 설계와 회고

매일 도는 흐름

1. **기상 수집**
   사내 기상 API에서 58개 격자 관측 · 예보 수집 (Python 3.7에서 동작 확인)
2. **정보 컷 패널**
   발표 2시간 전까지 들어온 원본만으로 단지별 입력 생성, 지연 · 짧은 이력 보정
3. **추론과 섞기**
   신경망 6개 + HGB, 8코어 16초 · 1.4 GB
4. **발행**
   CSV와 manifest(제외 사유 · 작동한 안전장치 기록), 다음 날 자동 채점 · 경보

실패하면

HGB 실패
신경망만으로 발행

둘 다 실패
최근 7일 같은 시각 중앙값 (pandas만으로 동작)

당일판 실패
하루 전 예측값 유지

월 재학습은 새 모델이 최근 2주에서 현행보다 MAE 2% 또는 R^2 0.005 이상 나쁘면 교체하지 않고, 이전 모델로 되돌릴 수 있게 했습니다.

배운 것

평가 기준부터 맞춥니다

처음엔 다섯 모델 · 네 기간이 모두 있는 42단지로 채점했는데, 요구는 부분수집을 포함한 전 단지였습니다. 기준을 바꾸자 예측 누락 문제가 드러났습니다.

한 계절로 결론 내지 않습니다

8월 결과만 보고 배포했다면 겨울에는 현행보다 MAE가 11% 나빴을 것입니다. 1월 · 2월 · 봄 · 8월 네 기간을 모두 봅니다.

인계는 받는 사람 기준으로

담당자 요청에 맞춰 전달본을 세 번 줄여 모델 · 가중치 · 입출력 규격만 남겼고, 서버와 같은 Python 3.7 환경에 풀어 예측 차이 0을 확인한 뒤 넘겼습니다.

남은 일

설계에 쓰지 않은 9월 이후 기간으로 같은 성능이 나오는지 재확인하는 일과, 실제 서버 배포가 남아 있습니다.

05 Lost in Quantization

The Refusals a 4-bit Checkpoint Flips and Its Chat Template Hides

기간 2026.10 – 2026.11 **형태** 개인 연구 · AAAI-27 Workshop on Deployable AI 제출 · 1저자 **기술** vLLM · NVFP4 · ModelOpt · RTX 5060 Ti × 2

소비자 GPU 한 장에 8B 모델을 올리려면 보통 남이 4비트로 양자화한 체크포인트를 받아 씁니다. 받은 NVFP4 체크포인트가 원본과 같은 유해 요청을 거절하고 같은 무해 요청에 답하는지, 영어와 한국어에서 다른지, 그 차이를 얼마나 믿을 만하게 잴 수 있는지 물었습니다.

짝을 이룬 요청 2,014개(유해 1,069 · 무해 945, 영어 · 한국어) · 8B 모델 3개(Qwen3 · Llama-3.1 · EXAONE-3.5) · 벤더 배포본과 자체 양자화본 · 블라인드 사람 라벨로 검증한 거절 판정기 2개

01 **채팅 템플릿이 양자화보다 크게 움직입니다.** NVIDIA의 Llama-3.1-8B NVFP4 배포본에 딸린 템플릿을 BF16 원본에 쓰기만 해도 한국어 유해 요청 거절률이 34.6%에서 62.7%로 오르고, 받은 그대로 비교하면 한국어 회귀가 가려집니다.

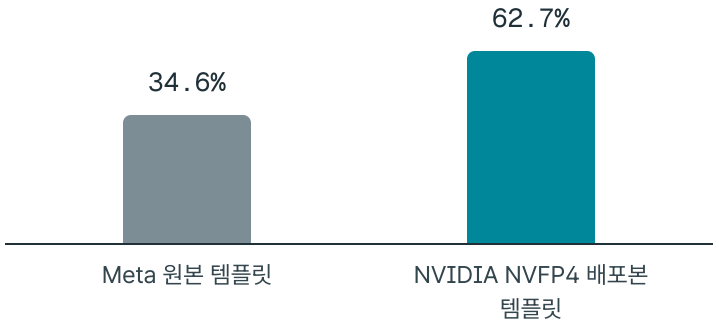
02 **순변화는 작아도 개별 응답은 뒤집힙니다.** 순 거절률 변화는 5%p 미만이지만 유해 요청의 5~10%가 거절에서 응답으로 바뀝니다. BF16을 다시 돌리기만 했을 때는 0.5~2.2%입니다.

03 **한국어가 더 흔들립니다.** 영어 · 한국어 격차가 가장 큰 모델에서 한국어 거절이 영어보다 3~9%p 더 자주 뒤집히고, 이중언어 보정 데이터로 양자화해도 줄지 않습니다.

04 **평가 환경도 결과의 일부입니다.** 같은 체크포인트를 GPU 2장에 나눠 돌리기만 해도 한국어 유해 요청의 최대 9%가 뒤집히고, 판정기는 바로 그 뒤집힌 응답에서 가장 부정확합니다.

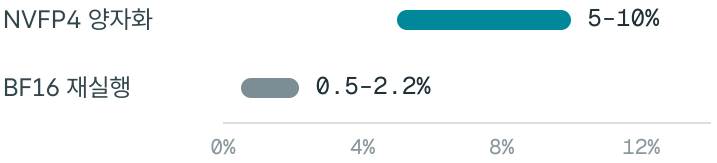
한국어 유해 요청 거절률 · Llama-3.1-8B BF16

같은 가중치, 채팅 템플릿만 다름



유해 요청이 거절 → 응답으로 뒤집힌 비율

Gemma-4-31B 판정 기준



측정을 믿을 수 있게 만든 과정

BASELINE

잡음 기준선부터 쟀습니다

- BF16 모델을 배치 순서만 바꿔 다시 돌린 결과를 기준선으로 두고, 양자화 효과는 항상 이 잡음과 비교했습니다.
- 잡음만으로도 한국어 거절이 영어보다 자주 뒤집혀서, 기준선 없이 비교하면 언어 특이적인 양자화 피해로 잘못 읽을 수 있었습니다.
- 템플릿 × 정밀도 2×2 설계로 템플릿 교란과 양자화 효과를 분리했습니다.

JUDGES

판정기를 사람 라벨로 검증했습니다

- 블라인드 라벨 화면을 만들어 응답 330개에 직접 라벨을 달고, 층화 표본의 포함 확률로 가중해 판정기 정확도를 추정했습니다.
- PolyGuard는 한국어 응답을 거절로 잘못 판정하는 경우가 많아(142개 중 32개) 주 판정기에서 뺐습니다.
- 판정 루브릭은 결과를 보기 전에 고정했고, 뒤집힌 응답에서 판정 정확도가 낮다는 점을 한계로 명시했습니다.

SYSTEMS

소비자 GPU에서 실행 환경을 맞췄습니다

- RTX 5060 Ti(sm_120) + CUDA 12.8 드라이버에서 vLLM NVFP4가 돌도록 휠 버전, Triton ptxas 경로, FlashInfer JIT 캐시, FP4 오토튜너 메모리 문제를 하나씩 풀었습니다.
- P2P가 없는 GPU 2장에서는 텐서 병렬 대신 파이프라인 병렬로 큰 판정 모델을 돌렸습니다.
- Qwen3-8B NVFP4 단일 GPU에서 배치 64 디코드 3,596 tok/s.

TAKEAWAY

배포 경로의 사소해 보이는 차이(채팅 템플릿, GPU 분할)가 양자화 자체만큼 결과를 바꿉니다. 모델을 서비스에 올릴 때 **받은 그대로의 체크포인트와 실제 서빙 설정으로 평가해야 하는 이유**를 숫자로 보였고, 논문의 모든 수치는 스크립트로 표 · 실험 출력과 대조했습니다.

06 한국 주식 수익률 예측: 과대평가를 걷어낸 기록

기간 2026.06 – 2026.10 **형태** 개인 프로젝트 · Python 패키지 spred **기술** pandas · LightGBM · PyTorch (LSTM, TFT) · Streamlit · FastAPI · cron

KOSPI 종목의 21일 뒤 수익률 순위를 예측하는 패키지를 만들고, walk-forward · 횡단면 IC · 롱숏 / 롱온리 수익 · 거래비용 · 시장 레짐까지 보는 평가 도구를 갖췄습니다.

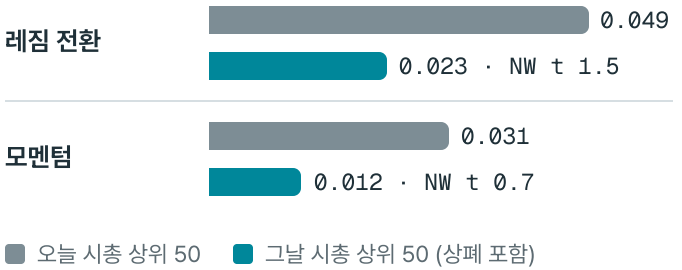
- **모델과 신호 조합을 바꾼 여섯 번의 시도**(Ridge · LightGBM 횡단면 모델, 멀티팩터 합성, LSTM, 수급 신호 추가, TFT 두 차례)가 모두 단순 12-1 모멘텀을 이기지 못했습니다. 병목은 모델이 아니라 신호라고 결론 냈습니다.
- 지수가 200일선 위면 모멘텀, 아래면 방어적 합성 신호를 쓰는 **레짐 전환 신호**가 처음으로 모멘텀을 이겼습니다.
- 시계열 인코더에 미래 수익률이 들어가 IC 0.935가 나온 **누설**을 발견해 고쳤습니다.

견고성 점검에서 걷어낸 것

- **중첩 표본:** 21일 타깃을 매일 찍어 t값이 3~4배 부풀어 있었습니다(naive t 5~10 → Newey-West t 1.5~2.8).
- **생존편향:** '오늘' 시총 상위 50종목 대신, 상장폐지 112종목을 포함한 '그날' 시총 상위 50종목으로 다시 평가했습니다.
- **남은 결론:** 레짐 전환이 모멘텀보다 낫다는 것은 세 유니버스 모두에서 유지됐고(IC 차이 NW t 3.3 / 1.7 / 2.7), 알파가 있다는 주장은 입증되지 않았습니다.

횡단면 IC, 유니버스 구성에 따른 변화

2015-07 ~ 2026-09 · 21일 수익률



좋아 보이던 숫자의 절반 이상이 표본 구성에서 나왔습니다. 이 경험 이후 업무에서도 결과가 좋을수록 표본과 누설을 먼저 확인합니다.

07 그 밖의 프로젝트

TIME SERIES

CoGenCast 재현과 디버깅

2026.06 · LLM + flow matching 시계열 모델

- 16GB GPU에서 전체 미세조정은 옵티마이저 상태만 약 14GB라 OOM. Qwen3 두 벌을 얼리고 마지막 4층만 학습해 약 1.35억 파라미터 · 7GB로 맞췄습니다.
- ETTh1 검증 손실이 318로 고정되는 버그: 값이 일정한 96시간 구간에서 정규화가 √1e-5로 나눠 입력이 316배가 됐습니다. 표준편차 하한을 넣어 MSE 1.17 → 0.342.
- 삼성전자 일간 수익률은 MSE로는 0 예측보다 나빴지만, CRPS로는 이동 변동성 가우시안보다 나았습니다(0.936 vs 0.955).

PyTorch | Transformers | CRPS

LLM AGENT

무료 로컬 음성 비서

2026.10 · Ollama qwen2.5:14b + 브라우저 음성 인식

- 모델이 도구를 직접 호출하게 하면 중첩 스키마를 틀리게 채우고 지명 질문에 빈 응답을 냈습니다.
- 모델은 JSON 스키마로 강제한 계획 폼(장소 · 주제)만 채우고, 도구 호출은 코드가 하도록 나눴습니다.
- 모델이 쓴 답에서 숫자가 빠지거나 한국어 중간에 중국어가 섞여, 기본 답은 코드의 문장 틀로 만들고 모델 다듬기는 선택으로 두었습니다(한자 감지 시 되돌림).

Ollama | JSON Schema | MCP | Web Speech

GPU

GPU 커널 학습과 배포 템플릿

2026.06 – · RTX 5060 Ti

- CUDA · Triton으로 행렬곱 · softmax · FlashAttention을 직접 작성하며 GPU 메모리 계층과 성능 측정을 공부하고 있습니다.
- 동료 배포용 PyTorch 확장 템플릿을 TORCH_LIBRARY + register_autograd로 만들어 backward · torch.compile과 호환되게 했습니다(pybind 방식은 둘 다 깨짐).
- 벤치마크에서 fused bias + GELU가 torch.compile과 fp32 동률, bf16에서는 0.75~0.92배라 배포하지 않기로 했습니다.

CUDA | Triton | torch.compile

읽어 주셔서
감사합니다.

프로젝트의 설계 근거와 실험 기록은 면접에서 더 자세히 설명드릴 수 있습니다.

이름	이성원 · Sungwon (Alex) Lee
이메일	sungwonlee.alex@gmail.com
LinkedIn	linkedin.com/in/sungwonalexlee